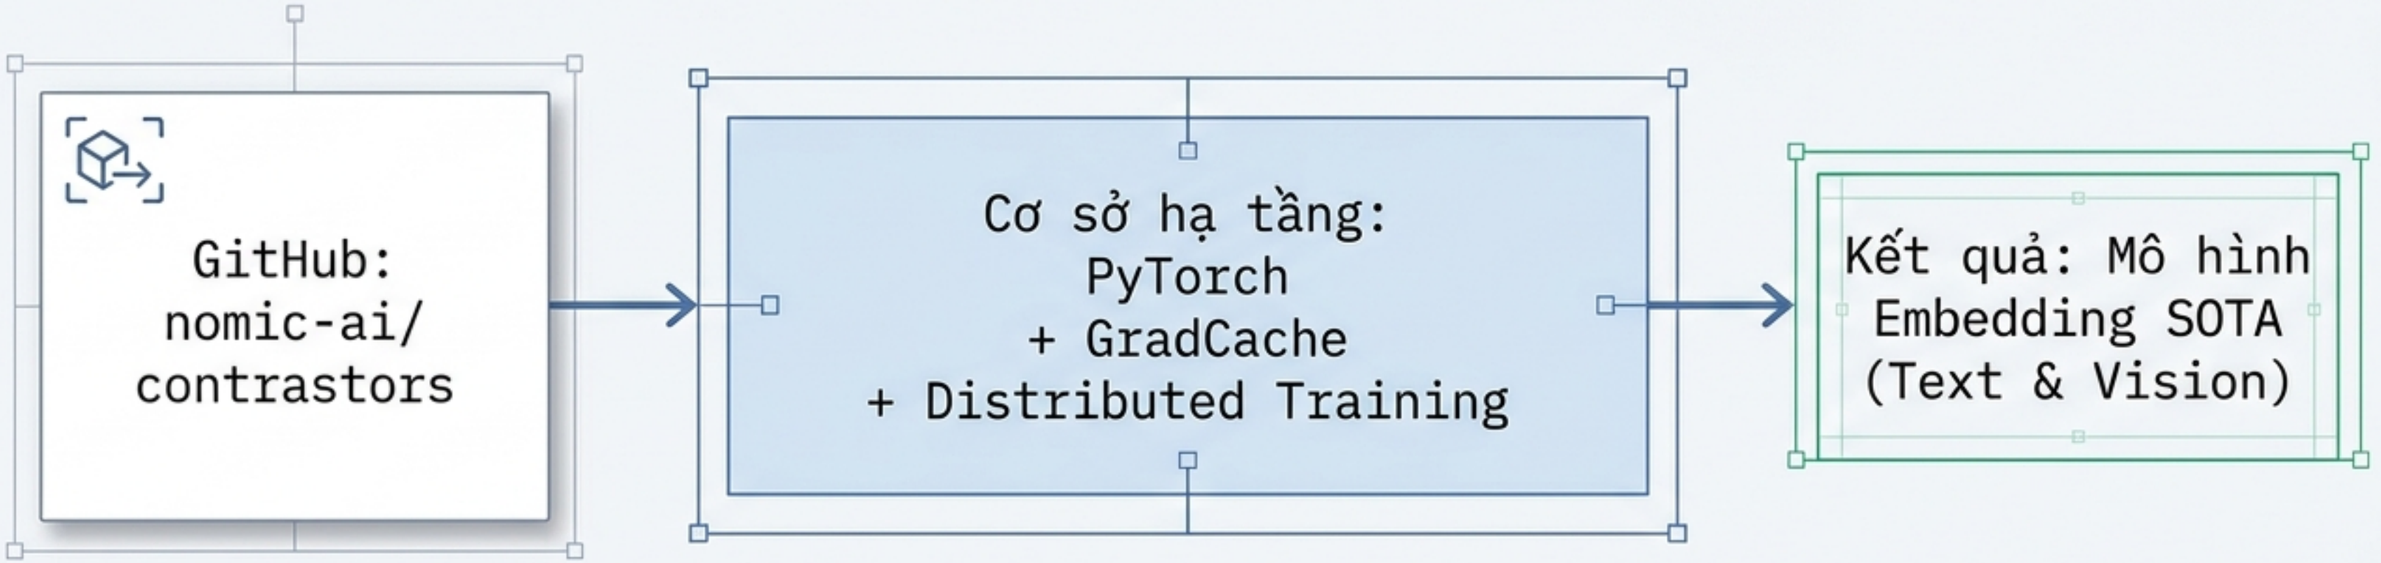
# Nomic AI Contrastors

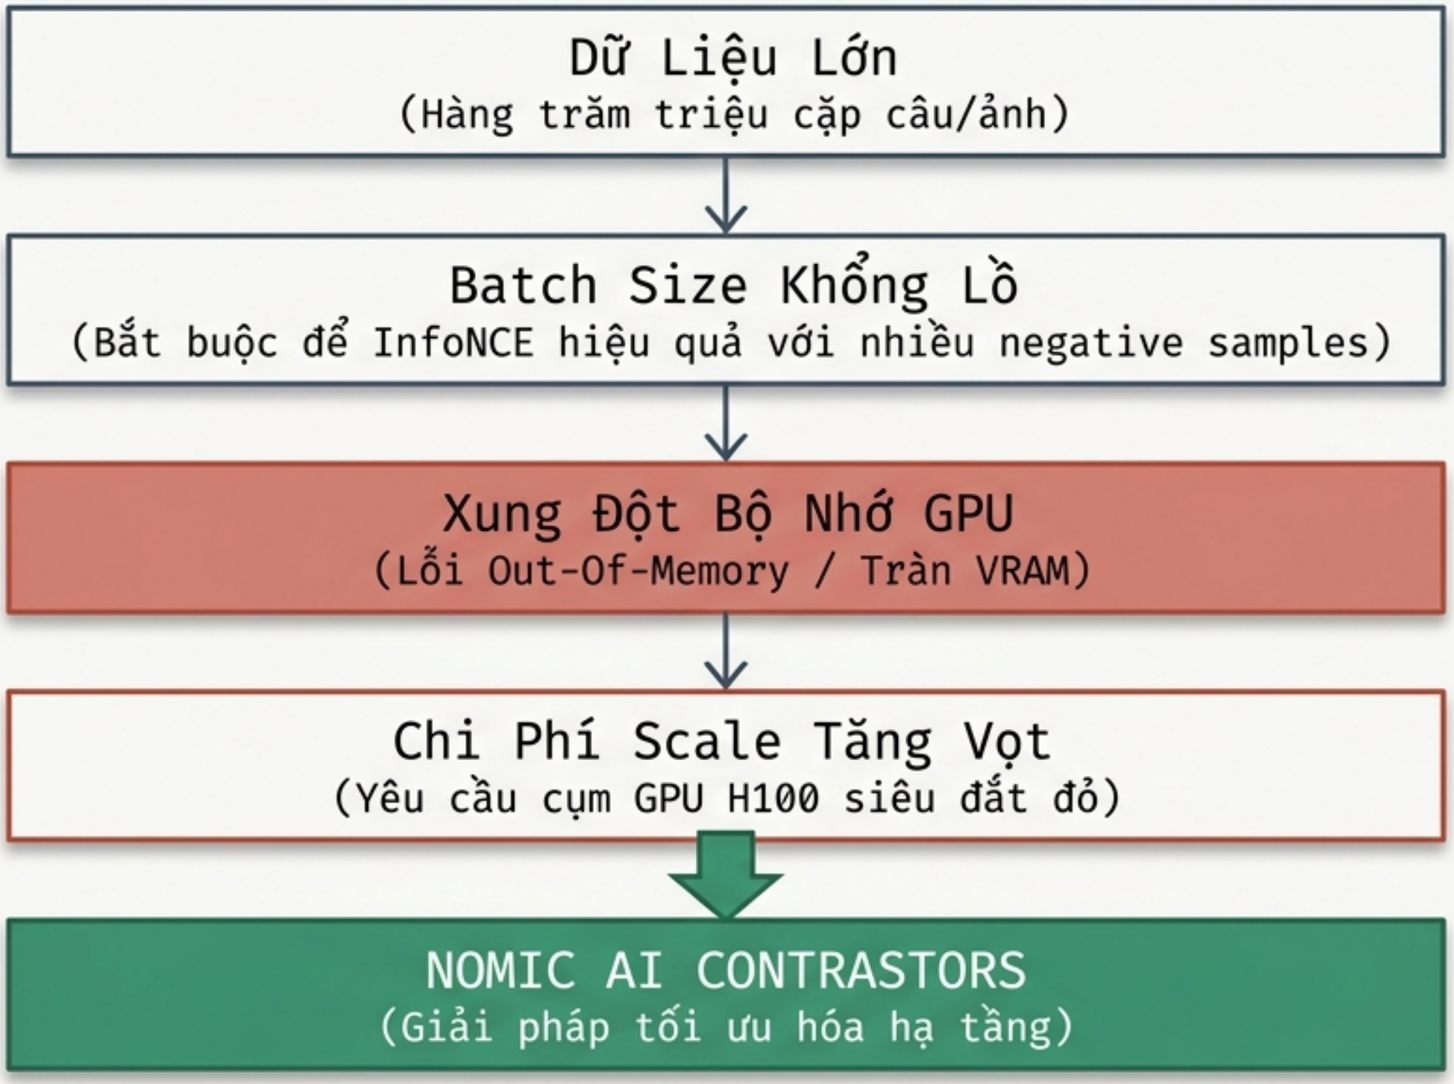
## Khung Làm Việc (Framework) Đào Tạo Các Mô Hình Contrastive Ở Quy Mô Lớn




Chào mừng các bạn. Hôm nay chúng ta sẽ đi sâu vào mã nguồn của Contrastors - một dự án mã nguồn mở từ Nomic AI. Bài thuyết trình này tập trung giải phẫu chính repository này: từ **kiến trúc, mã nguồn, pipeline huấn luyện** cho đến cách bạn có thể chạy và debug nó trên hệ thống của mình.

Gemini Notebook

# Tại Sao Chúng Ta Cần Contrastors?




Bản chất vấn đề: Contrastors không phát minh ra thuật toán mới.

Nó cung cấp hạ tầng kỹ thuật (**Engineering Infrastructure**) để giải quyết triệt để bài toán bộ nhớ và phân tán nhiều GPU, giúp việc huấn luyện tiết kiệm và khả thi.

Gemini Notebook

# Thực Chất Contrastors Là Gì?

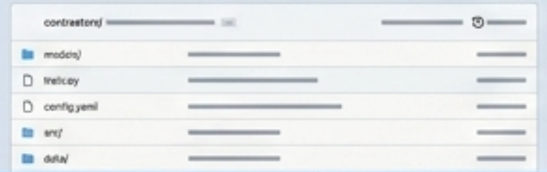
## Không Chỉ Là Một Mô Hình

- ✗ Không phải là một file Weights model.bin tĩnh.
- ✗ Không phải là thư viện lý thuyết học thuật.

## Contrastors Là Một Training Framework

- ✓ **Mã nguồn mở** (PyTorch): Thiết kế tối ưu cho luồng công việc contrastive.
- ✓ **Đa phương thức (Multimodal)**: Hỗ trợ Text (BERT, Pythia/GPTNeoX) và Vision (timm, CLIP).
- ✓ **Cơ sở hạ tầng toàn diện**: Bao gồm Model, Loss function, Vòng lặp huấn luyện, Tối ưu hóa (GradCache) và công cụ Đánh giá.

Khi bạn clone Contrastors, bạn đang tải về một nhà máy sản xuất mô hình, chứ không phải một sản phẩm tĩnh.




Gemini Notebook

# Bên Trong Mã Nguồn (Repository Tour)

```
contrastors/
├── docs/          # Tài liệu dự án
├── scripts/       # Chứa các script tạo/xử lý dữ liệu
├── src/
│   ├── contrastors/
│   │   ├── configs/   # Các file YAML cấu hình
│   │   └── train.py
│   ├── tests/         # Unit tests
│   ├── convert_to_hf.py
│   ├── test_grad_cache.py
│   └── tokenizer_compare.py
└── requirements.txt
```

### Trọng tâm

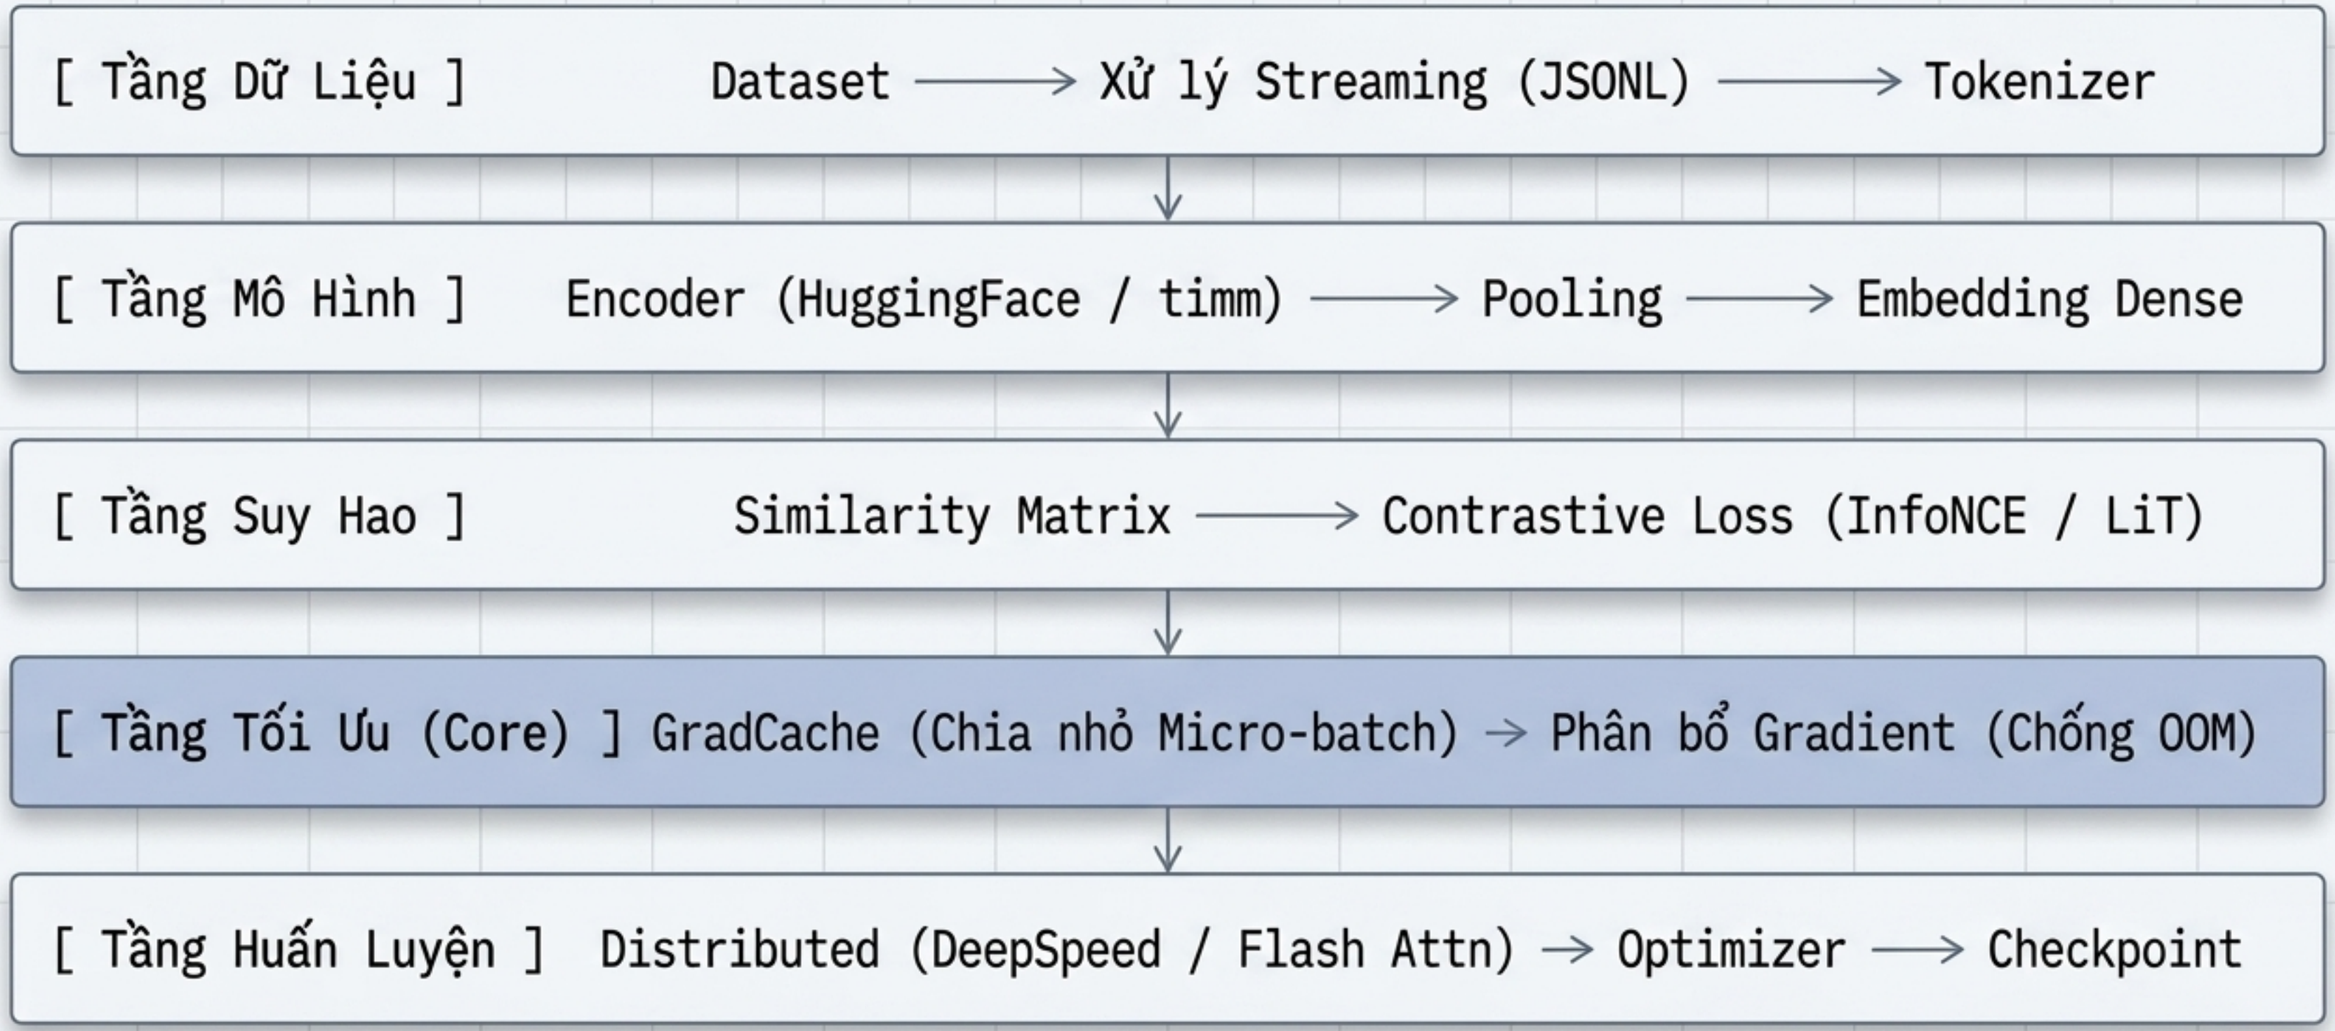
Thư mục `src/contrastors/` chứa toàn bộ logic huấn luyện cốt lõi. Điểm khởi chạy luôn là file `train.py`.

### Thực dụng

Các file ở thư mục gốc là các công cụ gỡ lỗi và triển khai thiết yếu (VD: `test_grad_cache`, `convert_to_hf`).

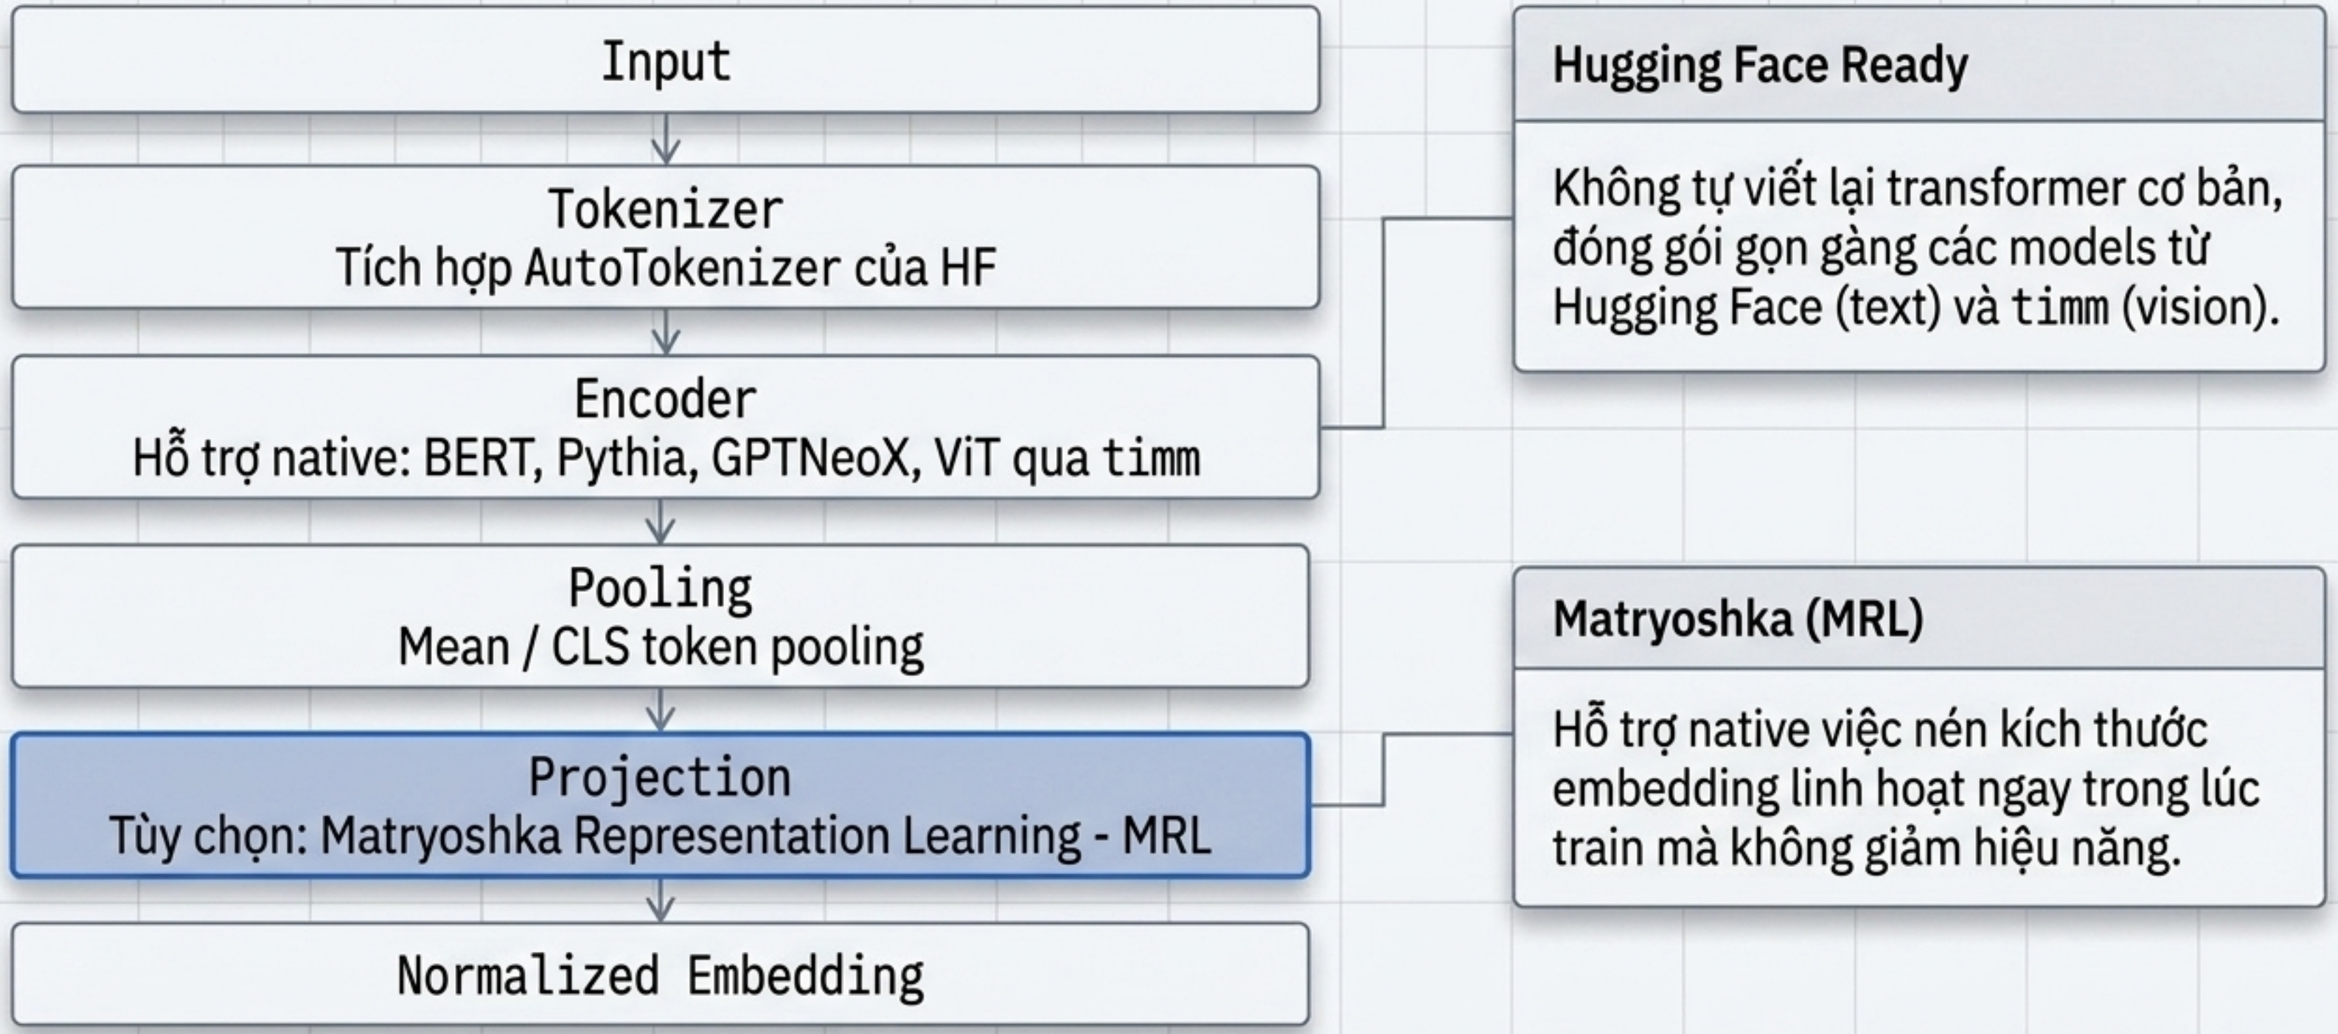
Gemini Notebook

# Kiến Trúc Tổng Thể: Sự Kết Nối Các Thành Phần



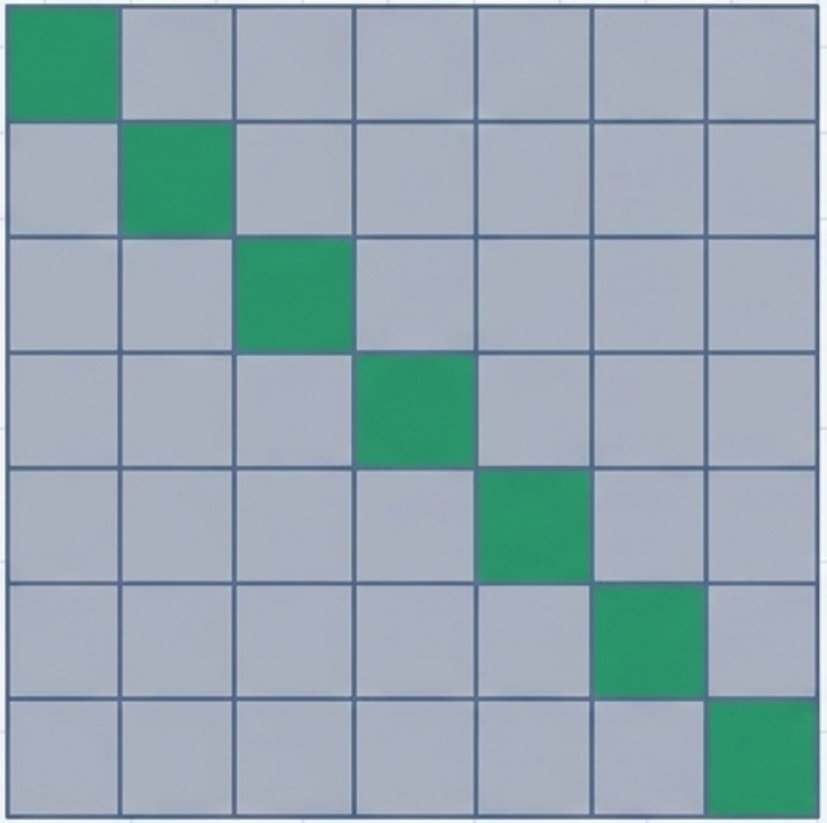

Gemini Notebook

# Triển Khai Mô Hình (Models Inside Contrastors)




Gemini Notebook

# Giải Phẫu Contrastive Loss Dưới Góc Độ Mã Nguồn



Positive Pairs (Đường chéo)

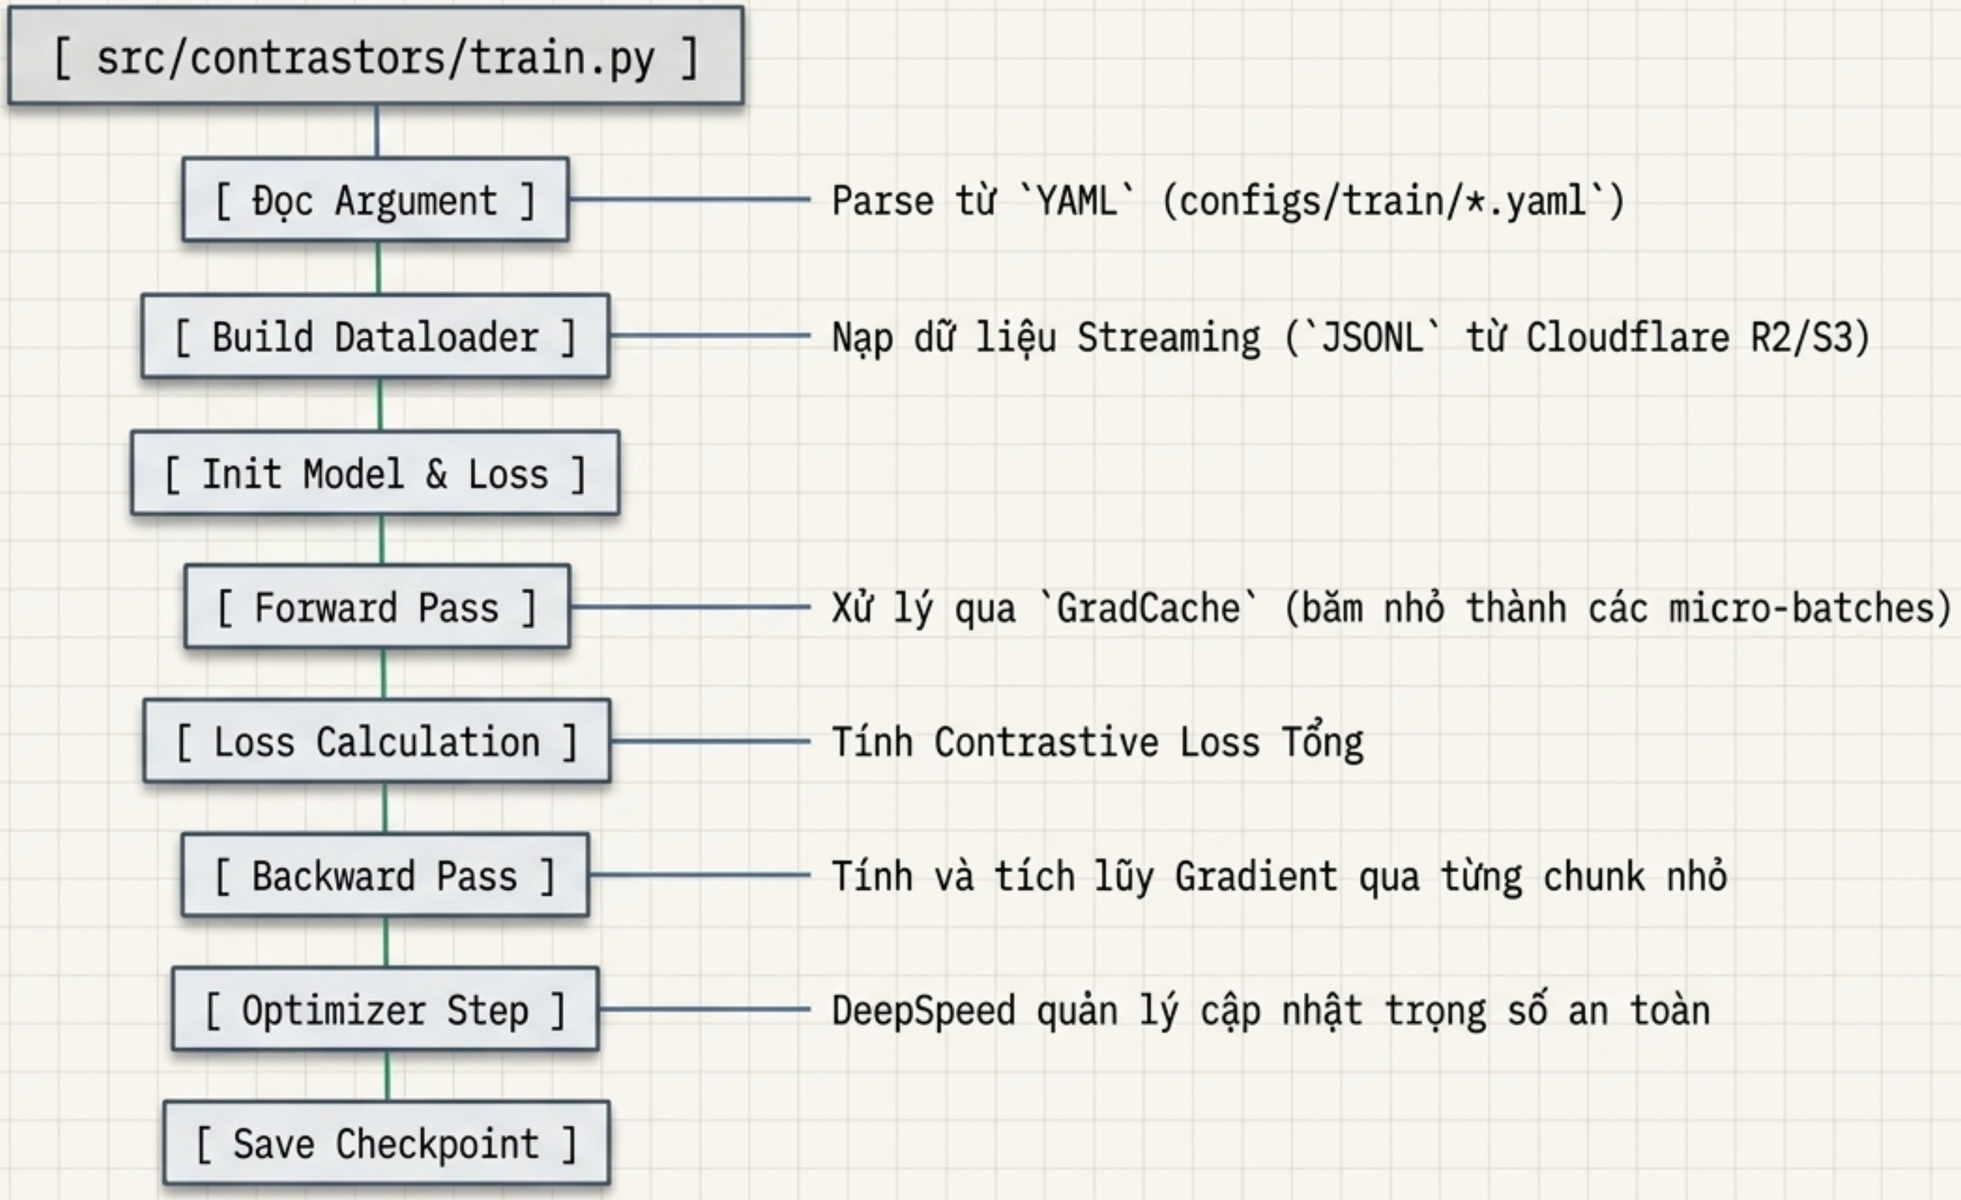
In-batch Negatives (Còn lại)

1. `Embedding A` & `Embedding B`
2. `Tính Dot Product` → Sinh ra Ma trận tương đồng / Similarity Matrix
3. `Xác định Lọc` → Đường chéo = Positive Pairs | Còn lại = In-batch Negatives
4. `Nhiệt độ (Temperature - τ)` → Phóng đại / Nội suy logit
5. `Cross-Entropy` → Tính Loss và Tích lũy Gradient

**Khác biệt kỹ thuật:** Thay vì truyền toàn bộ Batch qua mô hình cùng lúc, Loss trong Contrastors tính toán theo cơ chế `In-batch negatives` với nhiệt độ (τ) có thể học được hoặc cấu hình cứng.

Gemini Notebook

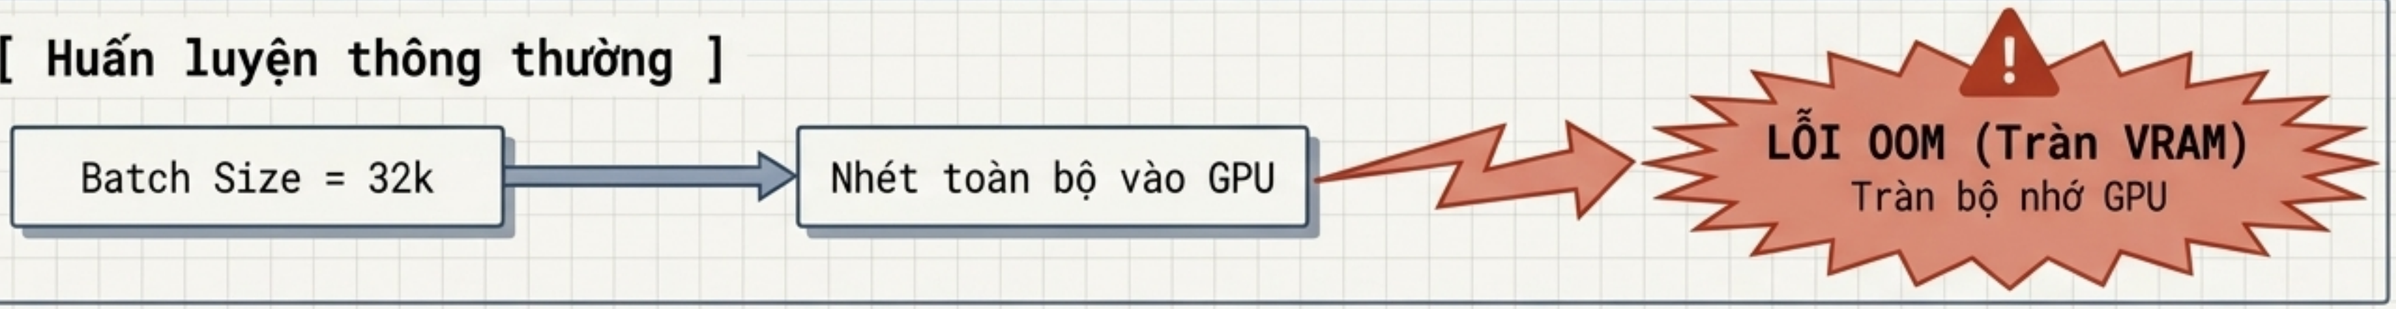
# Bên Trong Vòng Lặp Huấn Luyện (The Training Loop)



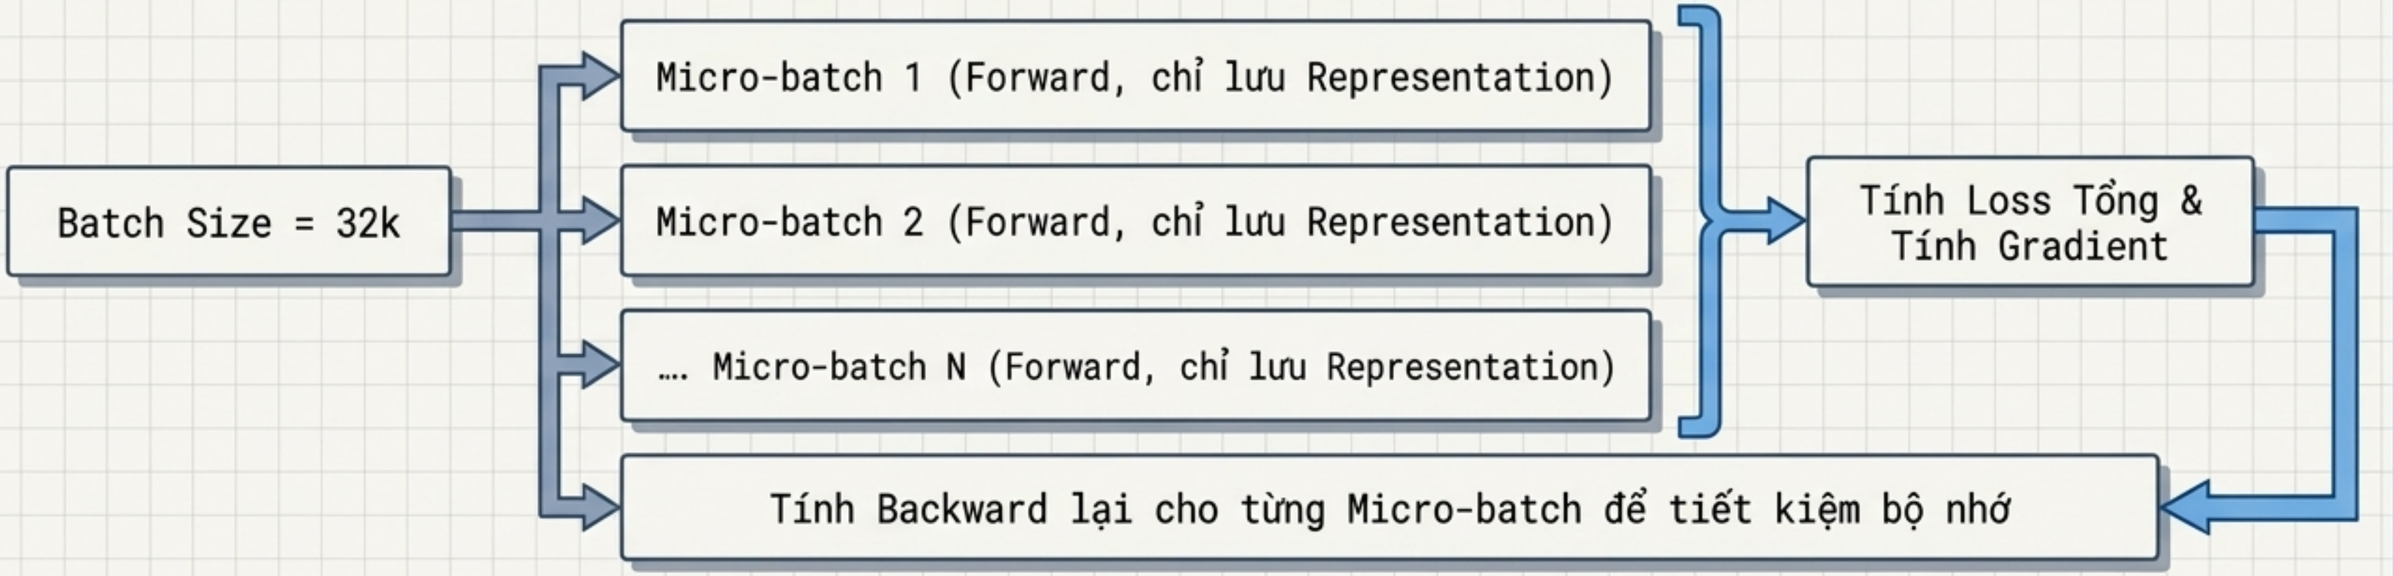

Gemini Notebook

# Vũ Khí Tối Thượng: GradCache

## [ Huấn luyện thông thường ]



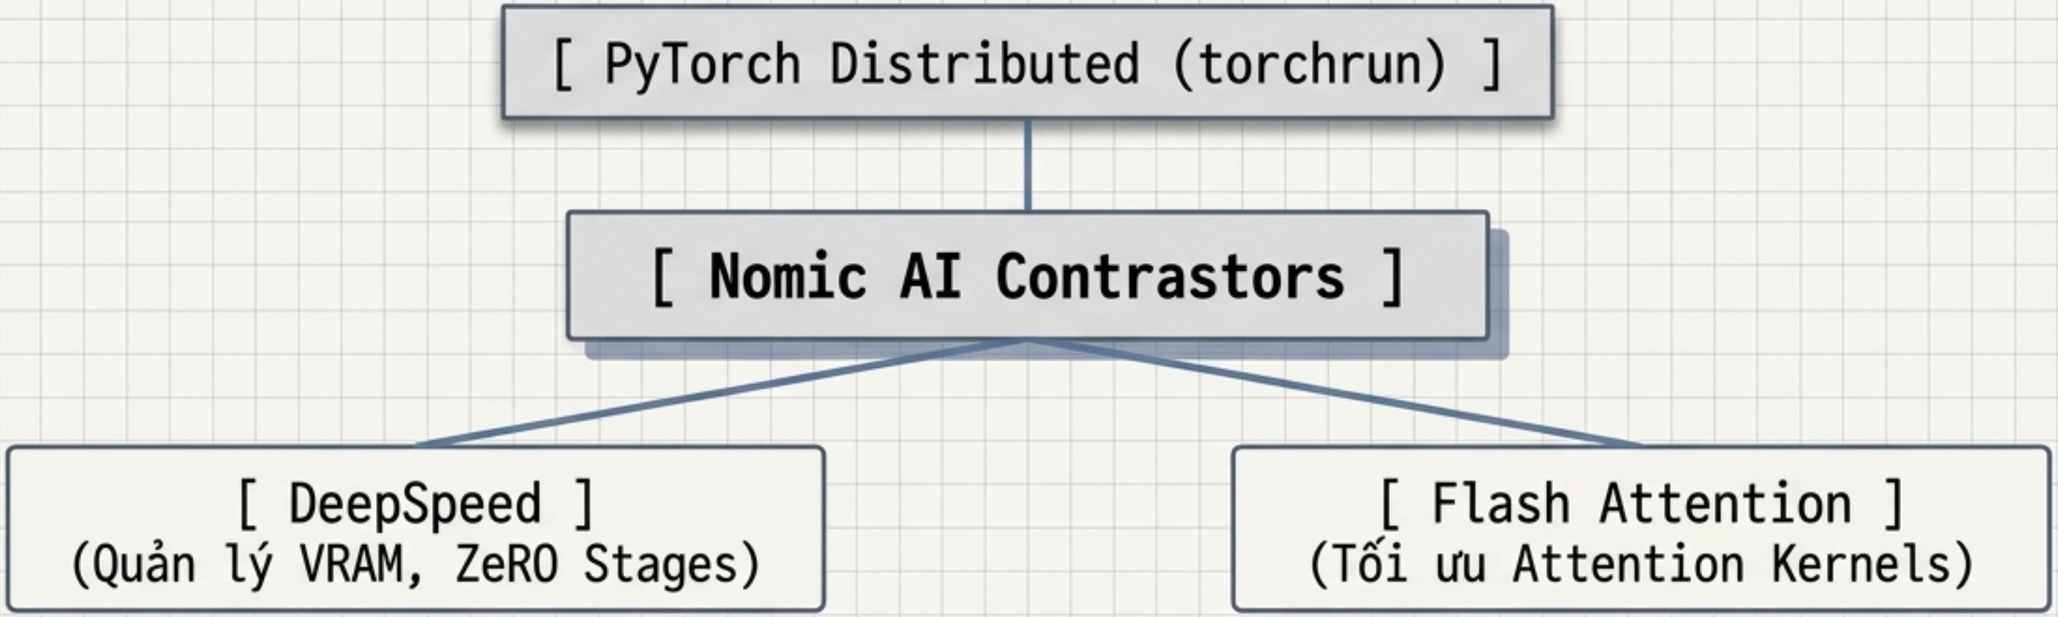

## [ Contrastors với GradCache ]




**GradCache** chia nhỏ dữ liệu thành micro-batches, chỉ lưu các biểu diễn (representations), tính toán Loss tổng, rồi quay ngược lại tính backward cho từng phần. Bộ nhớ sử dụng cực nhỏ nhưng hiệu năng toán học tương đương batch 32k.

Gemini Notebook

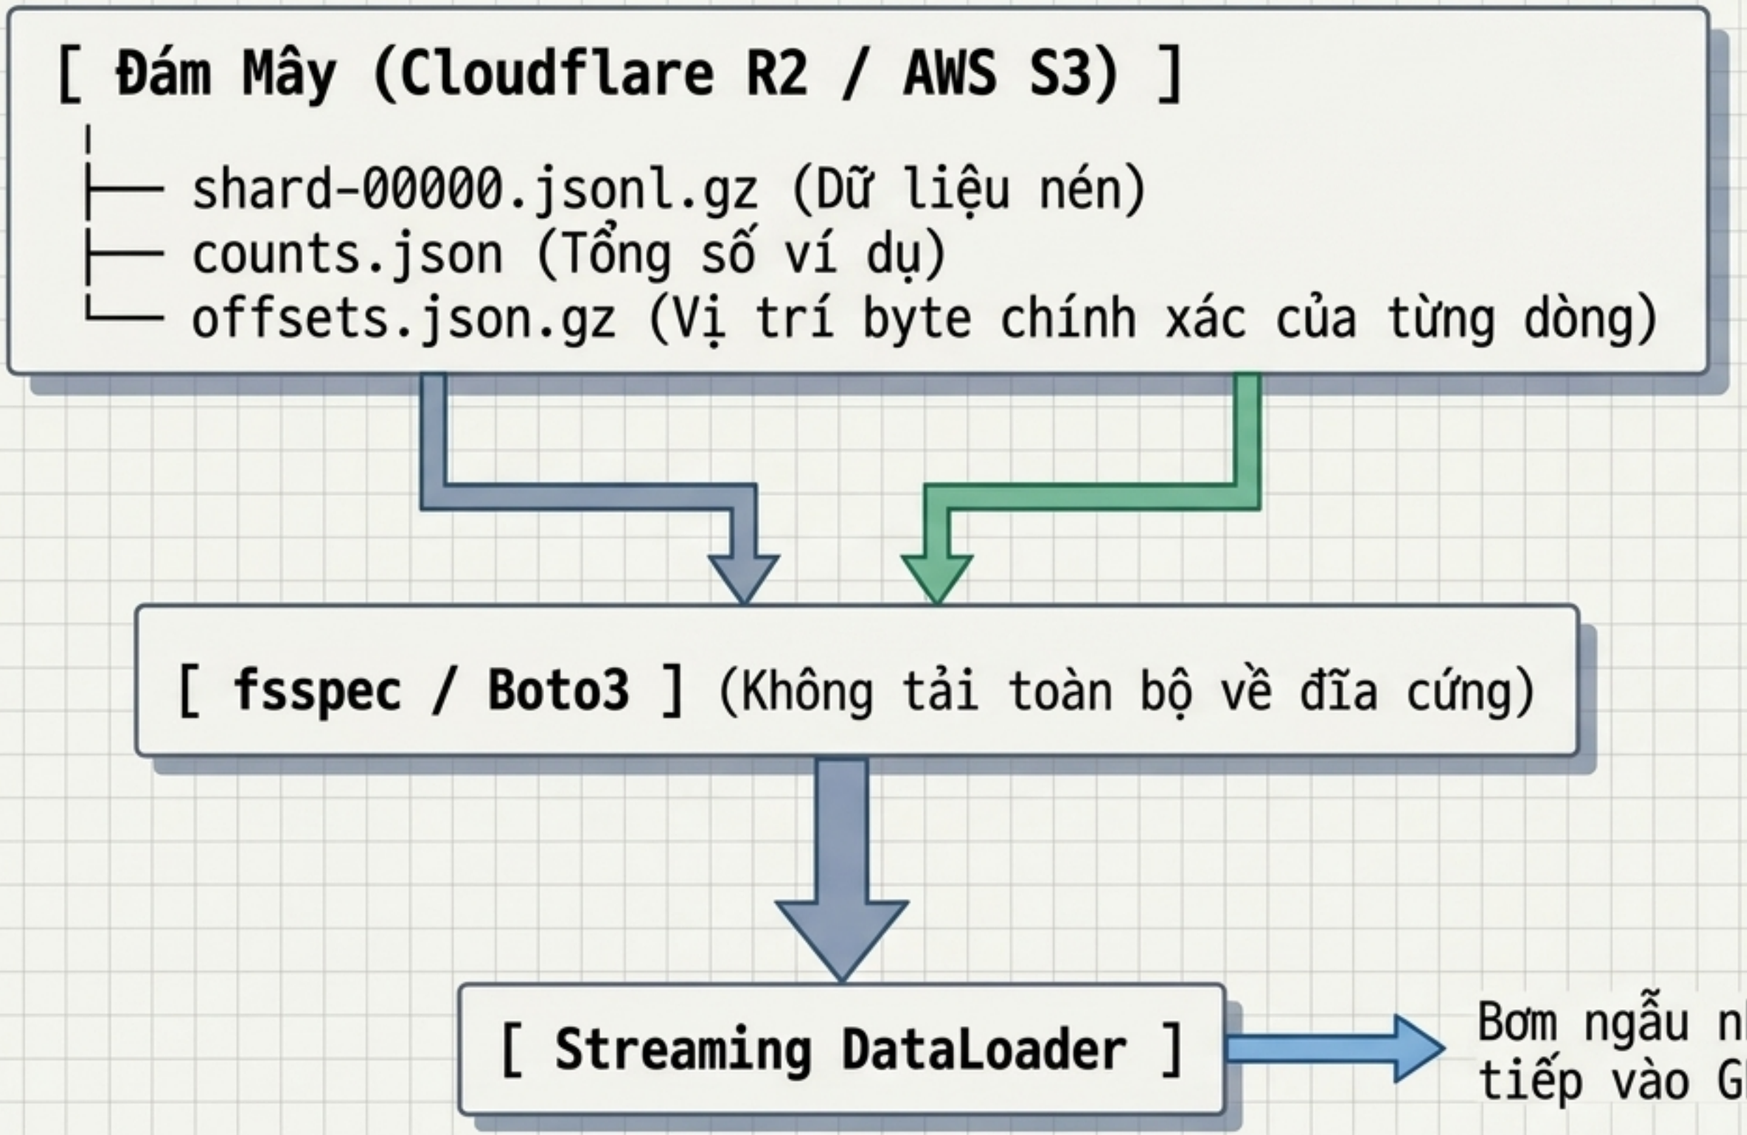
# Hệ Sinh Thái Đào Tạo Phân Tán (Distributed Training)




| DeepSpeed | Flash Attention Kernels |
| --- | --- |
| Tích hợp qua tham số **--deepspeed_config**.<br><br>Quản lý Sharded Optimizer States (ZeRO) giúp scale ra cụm hàng chục GPU mà không nghẽn. | Bắt buộc cài đặt các custom C++ kernels từ HazyResearch để đạt tốc độ tối đa:<br>- csrc/rotary<br>- csrc/layer_norm<br>- csrc/fused_dense_lib<br>- csrc/xentropy |

Gemini Notebook

# Xử Lý Dữ Liệu Khổng Lồ (Data Streaming)




**Cơ chế Byte-Offset:**

Contrastors sử dụng metadata (**offsets.json.gz**) để truy xuất ngẫu nhiên (random access) thẳng vào giữa file zip trên mạng.
Code tự động nhảy đến đúng vị trí byte và kéo dữ liệu, giải quyết triệt để bài toán nút thắt ổ cứng cục bộ.

Gemini Notebook

# Điều Khiển Qua YAML Configs

configs/train/contrastive_pretrain.yaml

```yaml
datasets:
  - name: paq
    bucket: s3://contrastive-index-filtered/
paq_full/shard-{00000..00538}.jsonl.gz
    query_prefix: search_query
    document_prefix: search_document
    objective:
      type: paired
      columns: [query, document]
```

S3/R2 Buckets: Trỏ trực tiếp đến kho dữ liệu đám mây.

Tiền tố (Prefixing): Thêm prefix cho Asymmetric Embedding trực tiếp qua config.

Objective linh hoạt: Đổi từ bài toán cặp câu (`paired`) sang bộ ba (`triplet - Query/Positive/Negative`) chỉ bằng 1 dòng, không cần sửa code PyTorch.

Gemini Notebook

# Cài Đặt & Khởi Chạy (Execution)

## 1. Môi trường & Flash Attention Kernels (Yêu cầu CUDA 11.8+):

```
pip install --no-cache-dir flash-attn --no-build-isolation
git+https://github.com/HazyResearch/flash-attention.git#subdirectory=csrc/rotary ...
pip install -e .
```

## 2. Xác thực Đám mây (Cloudflare R2):

Tạo file `~/.config/fsspec/s3.json` chứa `endpoint_url` và `aws_access_key_id`.

## 3. Lệnh Khởi Chạy Huấn Luyện:

```
cd src/contrastors
deepspeed --num_gpus=8 train.py \
    --config=configs/train/contrastive_pretrain.yaml \
    --dtype=bf16
```

*(Sử dụng `bf16` để tối ưu VRAM trên kiến trúc Ampere trở lên)*

Gemini Notebook

# Kiểm Thử & Gỡ Lỗi Trong Thực Tế (Debugging Tools)

## Công Cụ 1: `test_grad_cache.py`

**Khi nào dùng:** Khi Loss bất ngờ bùng nổ (nổ gradient) hoặc mô hình không hội tụ.

**Chức năng:** Kiểm tra trực tiếp xem việc phân mảnh Gradient qua micro-batches có bị sai lệch số học so với standard pass hay không.

## Công Cụ 2: `tokenizer_compare.py`

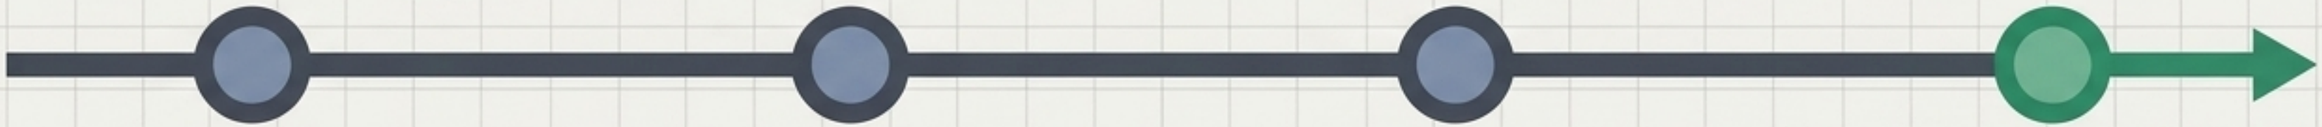
**Case Study Thực Tế:** Mô hình train xong nhưng infer ra vector rác.

**Nguyên nhân:** Xử lý `Padding/Truncation` hoặc thiếu token `<eos>` giữa lúc train và infer bị lệch nhau.

**Chức năng:** Đảm bảo Tokenizer của Nomic và Hugging Face khớp output 100% trước khi bắt đầu tốn tiền chạy GPU. Cập nhật `add_eos_token: true` trong YAML nếu phát hiện lỗi.

Gemini Notebook

# Tái Hiện Thực Tế: Nomic Embed Vision v1.5



### [ 1. Dữ Liệu ]

Sử dụng `img2dataset` tạo cặp Image-Text lớn.

### [ 2. Cấu Hình ]

Tùy chỉnh: `configs/deepspeed/image_text.json` và `nomic_embed_vision_v1.5.yaml`

### [ 3. Thực Thi ]

```
deepspeed train.py \
  --deepspeed_config=configs/deepspeed/image_text.json \
  --config=configs/train/nomic_embed_vision_v1.5.yaml \
  --dtype=bf16
```

### [ 4. Đóng Gói ]

Chạy `convert_to_hf.py` —> Upload trực tiếp lên Hugging Face Hub!

**Contrastors** không chỉ là một repo học thuật. Đây chính là khung làm việc (framework) nội bộ thực tế mà Nomic AI sử dụng để huấn luyện các mô hình dẫn đầu bảng xếp hạng MTEB hiện nay.

Gemini Notebook